

**POS-tagging для
української політичної
розмовної мови
на корпусі UD Ukrainian-
ParlaMint**

Голубнича
Маргарита
Станіславівна
ПМІД-11

Слайд 2 — Постановка задачі

- Що таке POS-tagging
- Part-of-Speech tagging (POS-tagging) — це задача автоматичного визначення частин мови для кожного токена в реченні.
- Мета проекту
- Побудувати модель, яка:
 - автоматично визначає частини мови українських слів;
 - працює з політичною розмовною мовою (стенограми парламенту);
 - забезпечує високу якість класифікації для різних моделей.

Чому це важливо

базова задача NLP;

використовується в
аналізі текстів;

необхідна для
подальших задач:
NER, parsing,
sentiment analysis;

складна для
української мови
через:

- багату морфологію;
- неоднозначність слів;

контекстну залежність.

**Що робилось у
проекті**

побудовано baseline-
модель;

проведено порівняння
кількох алгоритмів;

проаналізовано
помилки;

покращено якість
через feature.
engineering

Input Data (text tokens)



TF-IDF Vectorization



Machine Learning Model
(Logistic Regression / LinearSVC)



POS Prediction



Evaluation (Accuracy, F1-score)



Error Analysis

20XX

Рішення проекту

Використані методи

Векторизація

TF-IDF (word n-grams)

TF-IDF (char n-grams)

Моделі

Logistic Regression (baseline)

LinearSVC (основна модель)

Оцінювання

Accuracy

Macro-F1

Classification report

Ідея підходу

перетворення тексту → числові ознаки;

навчання класифікатора;

прогноз POS-тегів для кожного токена;

порівняння моделей.

Baseline МОДЕЛЬ

- **Модель: Logistic Regression + TF-IDF**
- **Ознаки (features)**
 - token-based text
 - TF-IDF (word n-grams)
- **Ідея baseline**
 - мінімальна модель без складних покращень;
 - працює тільки з окремими словами;
 - використовується як точка відліку для порівняння.
- **Результати (Validation)**
 - **Accuracy:** 0.812
 - **Macro-F1:** 0.708
- **Висновок**
 - baseline вже дає стабільний результат;
 - але погано працює з:
 - рідкісними класами;
 - контекстом;
 - морфологічними варіаціями.

- pipe1 = Pipeline([
- ("tfidf", TfidfVectorizer(ngram_range=(1,1))),
- ("clf", LogisticRegression(max_iter=300))
-])

- pipe1.fit(train_df["text"], train_df["upos"])

Модель	Accuracy	Macro-F1
Baseline	0.771	0.663
Improved baseline	0.822	0.695

Покращення baseline

Що було покращено

Після baseline було проведено feature engineering для підвищення якості моделі.

Основні зміни

1. Розширення ознак

token + lemma (об'єднання інформації)

word bigrams (1–2 n-grams)

sublinear TF scaling

2. Покращена модель

Logistic Regression

той самий алгоритм, але кращі ознаки

Висновок

додавання lemma покращує узагальнення;

bigrams допомагають враховувати контекст;

sublinear TF стабілізує ваги ознак;

загальний приріст якості $\approx +5\%$.

Експерименти з моделями

Моделі

Logistic Regression (baseline)

LinearSVC (word n-grams)

LinearSVC (word + char n-grams)

LinearSVC (balanced weights)

Ознаки (features)

Word-based

TF-IDF (word n-grams 1–2)

Character-based

TF-IDF (char n-grams 3–5)

дозволяє враховувати морфологію слів

Додаткові покращення

`class_weight = "balanced"`

покращення роботи з рідкісними класами

краще узагальнення на нові форми слів

Гіпотеза

char n-grams повинні покращити якість для:

складної морфології української мови

невідомих або рідкісних слів

LinearSVC (Word features)

```
vectorizer_word = TfidfVectorizer(  
    analyzer='word',  
    ngram_range=(1,2),  
    sublinear_tf=True  
)  
  
X_train_vec =  
vectorizer_word.fit_transform(X_train)  
  
svm_word = LinearSVC(C=1.0)  
svm_word.fit(X_train_vec, y_train)
```

LinearSVC (Word + Char + Balanced)

```
vectorizer_char = TfidfVectorizer(  
    analyzer='char',  
    ngram_range=(3,5),  
    sublinear_tf=True  
)  
  
X_train_char_vec =  
vectorizer_char.fit_transform(X_train)  
  
svm_char_balanced = LinearSVC(  
    C=1.0,  
    class_weight='balanced'  
)  
  
svm_char_balanced.fit(X_train_char_vec, y_train)
```

Порівняння моделей

- Результати на валідації
- Порівняння всіх протестованих моделей:
- Основні спостереження
- LinearSVC значно перевищує Logistic Regression;
- char n-grams дають найбільший приріст якості;
- class balancing покращує Macro-F1;
- модель добре узагальнює навіть на складних формах слів.

Модель	Accuracy	Macro-F1
Logistic Regression (baseline)	0.812	0.708
LinearSVC (word n-grams)	0.856	0.745
LinearSVC (word + char n-grams)	0.973	0.835
LinearSVC (balanced weights)	0.971	0.836



Confusion Matrix

Аналіз помилок класифікації

Baseline (Logistic Regression)

Найкраща модель (LinearSVC + word+char + balanced)

Основні спостереження

1. Baseline модель

часті помилки між:

NOUN ↔ PROP

VERB ↔ AUX

PART ↔ CCONJ



багато неправильних передбачень для PUNCT


2. Покращена модель (LinearSVC)

значно менше помилок загалом;

краща роздільність класів;

стабільніше визначення морфологічних категорій.





PR Curve та imbalance класів

Проблема незбалансованості класів

У датасеті є суттєва нерівномірність розподілу POS-тегів:

Найчастіші класи: NOUN, PUNCT, VERB

Рідкісні класи: INTJ, NUM

Вплив imbalance

модель краще навчається на частих класах;

рідкісні класи мають гірші метрики;

Macro-F1 знижується через слабкі класи.

PR Curve (PUNCT)

показує баланс між precision та recall;

використовується для оцінки якості на конкретному класі;

Feature Importance (Top features)

- Висновок
- модель вивчила реальну політичну лексику;
- чітко розрізняє частини мови за контекстом;
- char n-grams допомагають стабілізувати морфологічні форми.

POS tag	Top features (найважливіші ознаки)
NOUN	закон, депутат, питання, рішення, пропозиція
PROPN	Україна, Володимир, Янукович, Сергій, Олександр
VERB	працювати, сказати, просити, хотіти, мати
ADJ	український, державний, політичний, національний, відповідний
PUNCT / AUX	".", ",", бути, буде, були

Аналіз помилок (baseline модель)

True	Pred	Коментар
NOUN	PUNCT	найчастіша помилка
ADJ	PUNCT	часта плутанина
VERB	PUNCT	помилки через контекст
CCONJ	PUNCT	слабке розпізнавання зв'язків
PRON	PUNCT	розрив контексту

Загальна кількість помилок

Базова модель (Logistic Regression)

Кількість помилок: **≈1954**

Основні причини помилок

1. Сильний перекид у бік PUNCT

модель “переучилася” на часту пунктуацію

2. Обмежені ознаки baseline

тільки word TF-IDF

відсутність char-інформації

3. Морфологічна неоднозначність

PROPN vs NOUN

VERB vs AUX

Висновки

- **Основні результати**
- Побудовано систему POS-tagging для української політичної розмовної мови
- Реалізовано кілька підходів:
 - Logistic Regression (baseline)
 - LinearSVC (word / char n-grams)
- **Найкраща модель**
- **LinearSVC + word & char n-grams + balanced weights**
- Результати:
 - Accuracy $\approx$ **0.97**
 - Macro-F1 $\approx$ **0.836**
- **Головні покращення**
- char n-grams $\rightarrow$ найсильніший приріст якості
- LinearSVC $\rightarrow$ стабільніша модель ніж Logistic Regression
- class_weight $\rightarrow$ краща робота з рідкісними класами
- **Висновок по задачі**
- задача POS-tagging для української мови є складною через:
 - морфологічну варіативність
 - розмовний стиль
 - неоднозначність тегів

Де це можна використовувати

